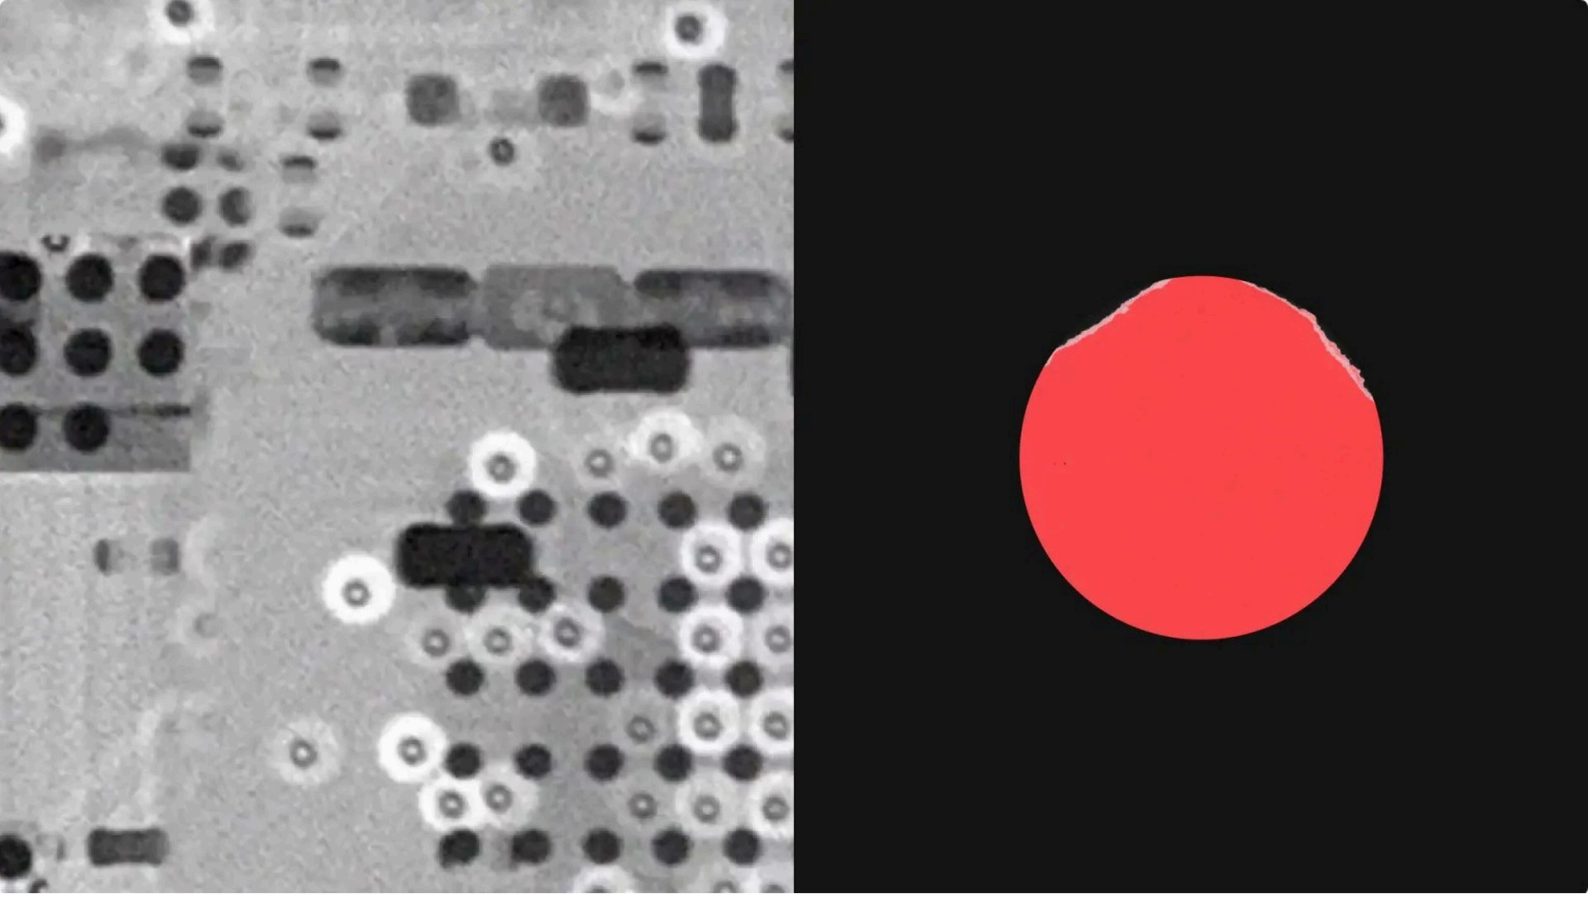


OBLIVION / TECHNICAL RESEARCH

DIE GLM-MODELL FAMILIE

Technische Analyse der Z.ai-Modelle von GLM-130B bis 5.3 und der Spezialzweige

Engineering-Recherche · Architekturvergleich · Kritische Bewertung für Oblivion

26. Oktober 2026 | Research-Ausgabe 1.1

GLM ist eine Modellfamilie, kein einzelnes Modell

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

GLM gehört zu Z.ai (früher Zhipu AI), nicht zu Anthropic. Die Familie entwickelte sich von vortrainierten Sprachmodellen zu Reasoning, agentischer Softwareentwicklung, Vision, OCR, Sprache und Bildgenerierung. Diese unterschiedlichen Zweige mit einer einzigen Intelligenzkennzahl oder nur anhand der Parameterzahl zu vergleichen, ist technisch nicht belastbar.



Konzeptuelles Infrastrukturmotiv für die Erzählung; keine verifizierte Fotografie eines Z.ai-Rechenzentrums.

1M	744–753B	320B / 18B	0.9B
Nominaler Kontext · GLM-5.2 / 5.3	Gemeldete Gesamtgröße · GLM-5.3	Gesamt / aktiv · GLM-5.3-Flash	Ungefähre Größe · GLM-OCR

Engineering-Fazit für Oblivion

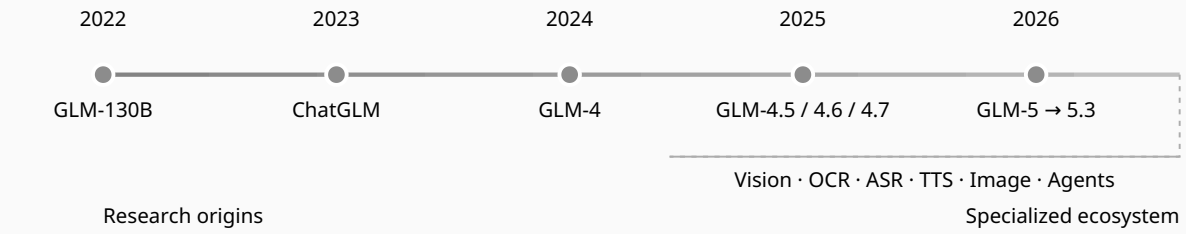
GLM-5.3 ist das Text-Flaggschiff für komplexes Coding und langfristige Aufgaben. **GLM-5.3-Flash** ist ein multimodaler Zweig mit neuer Basis, kein leichtes 18B-Modell. Für begrenzte lokale Hardware sind **GLM-4.7-Flash** und kleine Spezialmodelle wie **GLM-OCR** realistischere Ausgangspunkte. Bild-, Dokument- und Sprachaufgaben sollten gezielt geroutet werden.

> **Endgültige Einordnung**
>
> Die Stärke von GLM liegt in der Breite der Modellfamilie und dem Zugang zu Gewichten. Herausforderungen sind heterogene Versionen, reale Kosten großer Checkpoints, Abhängigkeit vom Agent Harness und unterschiedliche Benchmarkbedingungen. Oblivion sollte einen modellunabhängigen Router bauen, statt ein Produkt an einen Modellnamen zu koppeln.

Umfang: öffentlich nachvollziehbare Z.ai-Modelle und Produkte zum 26. Oktober 2026. APIs, veröffentlichte Gewichte, historische Modelle und benachbarte Produkte werden getrennt betrachtet.

Von GLM-130B zur multimodalen Familie

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Linie auf Grundlage der öffentlich dokumentierten GLM-Familie; Spezialzweige werden später getrennt behandelt.

GLM steht ursprünglich für **General Language Model**. Die Forschungsfamilie wurde 2022 mit GLM-130B bekannt. ChatGLM erweiterte 2023 den Konversationszweig; GLM-4 baute 2024 Dialog-, Vision- und Tool-Funktionen aus. Heute umfasst das Z.ai-Portfolio Basismodelle, APIs und vollständige Agentensysteme – keine homogene LLM-Reihe.

Zeitraum	Beispiele	Korrekte Einordnung
2022	GLM-130B, GLM-10B	Frühe Forschungsmodelle; kein fairer direkter Vergleich mit heutigen Flaggschiffen.
2023	ChatGLM, ChatGLM2, ChatGLM3	Konversationszweig mit 6B; vor allem historischer Kontext.
2024	GLM-4, GLM-4-9B, GLM-4V-9B, GLM-4-Voice	Ausbau um offene Gewichte, Vision und Sprache.
2025	GLM-4.5/Air, 4.6, 4.7, V-Reihe	Große MoE-Modelle, hybrides Reasoning und agentisches Coding.
2026	GLM-5, 5.1, 5.2, 5.3, Flash	Langfristige Aufgaben, Million-Token-Kontext und neue Multimodalität.

> **Was „alle GLM-Modelle“ hier bedeutet**
>
> Der öffentliche Hub enthält zahlreiche BF16-/FP8-Artefakte, Basismodelle und Spezial-Checkpoints. Dieser Bericht behandelt identifizierbare offizielle Familien; nicht jede Quantisierung, jedes Drittanbieter-Fine-Tuning oder Provider-Alias wird als eigene Generation gezählt.

GLM-4-Voice, GLM-Realtime, AutoGLM, GLM-PC und AutoGLM-Phone sind verwandte Produkte oder Agentensysteme und nicht sämtlich Text-LLMs. CogVideoX gehört zum weiteren Z.ai-Portfolio, ist aber nicht automatisch ein GLM-Modell.

Die Entwicklung von GLM-4.5 bis GLM-5.3

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

GLM-5.3	GLM-5.3-FLASH	GLM-4.7-FLASH
744B / 40B active	320B / 18B active	31B / 3B active
TEXT · LONG-HORIZON	MULTIMODAL · MoE	LOCAL TESTING
Flagship	New base	Compact family

Modellgrößen und aktive Parameter gemäß offiziellen Model Cards und Repositories; aktive Parameter sind nicht der gesamte Gewichtsspeicher.

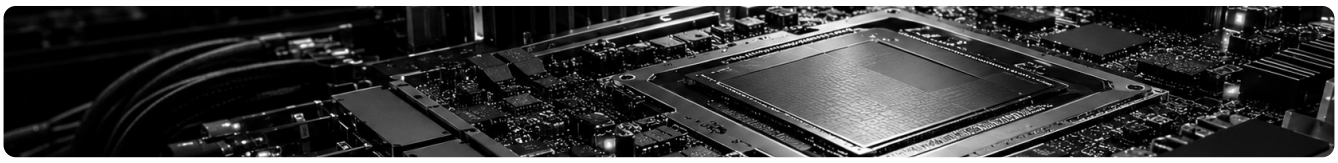
Modell	Wesentliche Spezifikation	Technische Rolle
GLM-4.5	355B gesamt / 32B aktiv; MoE	Grundlage für Agenten, Reasoning und Coding; Thinking- und Non-Thinking-Modi.
GLM-4.5-Air	106B gesamt / 12B aktiv	Kleineres Geschwistermodell, aber kein Laptop-Modell.
GLM-4.6	Etwa 355B-A32B; bis 200K	Verbessertes Coding, Suche, Tool-Nutzung und Agent-Workflows.
GLM-4.7	Etwa 355B-A32B	Verbesserungen bei ausgewählten Coding- und Tool-Benchmarks.
GLM-4.7-Flash	Etwa 30B-A3B	Kleinerer Textzweig; besser für quantisierte lokale Tests geeignet.
GLM-5	Etwa 744B / 40B aktiv; 28,5T Trainings-Token	Komplexe Systementwicklung und langfristige Agent-Aufgaben.
GLM-5.1	Flaggschiff für agentisches Coding; dokumentiert 200K	Mehrstufiges Coding; lange autonome Läufe hängen vom Harness ab.
GLM-5.2	Eine Million Token Kontext	Langfristige Aufgaben und Effizienz bei langem Kontext.
GLM-5.3	Etwa 744–753B / 40B aktiv; 1M	Gleiche Basis wie 5.2, stärkeres Post-Training.
GLM-5.3-Flash	320B gesamt / 18B aktiv; 1M	Neue Basis und multimodal; Flash bedeutet nicht 18B Gesamtgröße.

> **Warum GLM-4.7-Flash weiterhin wichtig ist**
>
> Der Gesamt-Checkpoint ist deutlich kleiner als bei GLM-5.3-Flash. Für agentische Coding-Experimente auf begrenzter Hardware ist es möglicherweise der praktischere Startpunkt. Qualität, Speicher und Geschwindigkeit müssen dennoch mit festgelegter Quantisierung und Runtime gemessen werden.

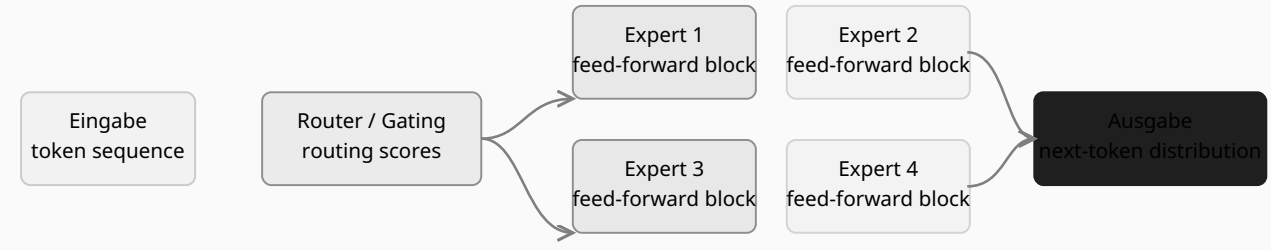
Modell-ID, Checkpoint-Datum, BF16-/FP8-Format, Kontext, Lizenz und Endpoint gemeinsam dokumentieren. Aliase wie „latest“ können sich je nach Zeitpunkt und Anbieter ändern.

MoE, Sparse Attention und langer Kontext

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Konzeptvisualisierung von Rechenhardware; die Multimodal-Grafik klassifiziert Fähigkeiten und zeigt keine interne Routing-Topologie.



Ausgewählte Experten · illustrative sparse routing, not an exact expert map

Konzeptionelle Neuzeichnung auf Grundlage des GLM-5-Technikberichts; keine exakte Abbildung sämtlicher Schichten.

Die Flaggschiffe GLM-4.5 und GLM-5 verwenden **Mixture-of-Experts**. Ein Router aktiviert pro Token nur einen Teil der Experten und senkt so den Rechenaufwand pro Token gegenüber einem ähnlich großen Dense-Modell. Nicht aktivierte Experten bleiben jedoch im Checkpoint; die vollständigen Gewichte müssen im Speicher oder über Offload verfügbar sein.

Merkmal	GLM-5.3	GLM-5.3-Flash
Gesamtgröße	Etwa 744B im README; 753B im HF-Katalog	Etwa 320B bei NVIDIA / HF
Aktive Parameter	Etwa 40B	Etwa 18B
Kontext	1.048.576 Token im Model Card	1M angegeben; Qualität und Durchsatz bei voller Länge testen
Eingabe	Text	Text und Bilder; Video abhängig vom Endpoint
Hauptunterschied	5.2-Basis mit stärkerem Post-Training	Neue Basis, 30T multimodale Token, Sparse + Linear Attention, mHC

Mechanismen der Generation 5

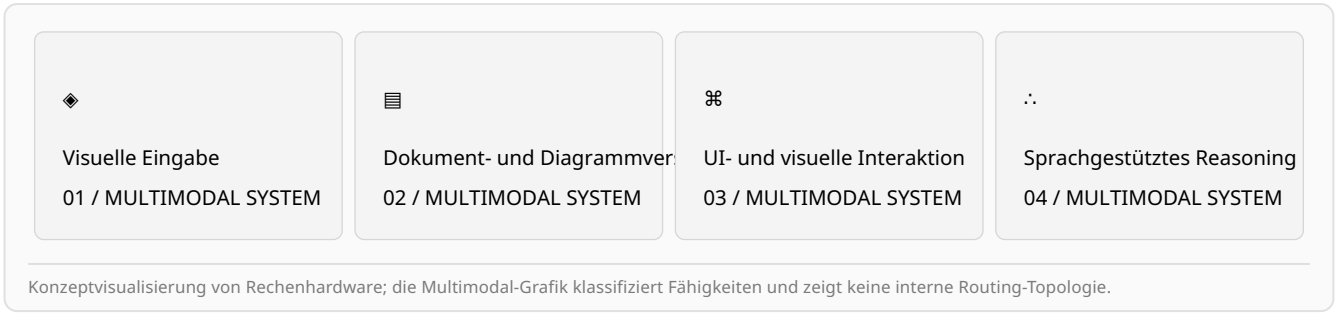
- **DSA:** Wählt relevante Teile langen Kontexts, statt alle Token dicht zu attendieren.
- **IndexShare:** Teilt einen Indexer über ausgewählte GLM-5.2-Layer; die 2,9-fache FLOPs-Reduktion ist ein Herstellerwert unter bestimmten Bedingungen.
- **Hybrid Attention:** GLM-5.3-Flash kombiniert Sparse- und Linear-Pfade, um die Serving-Kosten langer Kontexte zu senken.
- **mHC / MTP:** Hyper-Connections und Multi-Token Prediction unterstützen Skalierung und Speculative Decoding.

> **Kapazität nicht mit Leistung verwechseln**
>
> Ein Limit von einer Million Token beweist nicht, dass die volle Länge schnell, günstig oder präzise verarbeitet wird. Durchsatz, Fernabruf, KV-Cache, Batch und Speicher separat messen.

Öffentliche GLM-5.3-Listen nennen je nach Artefakt- und Model-Card-Konvention 744B oder 753B. Dieser Bericht dokumentiert beide Werte.

GLM-V und GLM-5V-Turbo

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Konzeptvisualisierung von Rechenhardware; die Multimodal-Grafik klassifiziert Fähigkeiten und zeigt keine interne Routing-Topologie.

Modell	Größe / Generation	Zielkompetenz
GLM-4.1V-9B-Thinking	Etwa 9B; 64K	Visuelles Reasoning über Bilder, Diagramme und Dokumente.
GLM-4.5V	Etwa 108B	Bild-, Video- und Dokumentverständnis, Visual Grounding und GUI.
GLM-4.6V	Etwa 108B; Flash etwa 9–10B	Bild-Text-Mischung, lange Dokumente, Diagramme und UI-Rekonstruktion.
GLM-5V-Turbo	Multimodale Coding-Basis als API	Text-, Bild-, Video- und Dateieingabe; visuelles Coding und GUI.
GLM-5.3-Flash	320B gesamt / 18B aktiv	Laut Z.ai erstes nativ multimodales GLM-5-Modell; Text- und Bildeingabe.

Reale Einsatzfelder für Vision

- Verständnis von Screenshots, Diagrammen und UI-Layouts
- Informationsextraktion aus Scans und Dokumenten
- Umsetzung visueller Evidenz in UI-Code
- Video- und Frame-Analyse nur bei expliziter Endpoint-Unterstützung

> **Implementierungshinweis für Oblivion**
>
> Originalbild, Abmessungen, Crops, Vorab-OCR und Quelldatei erhalten. Vom Modell vorgeschlagene Klicks oder Dateiänderungen vor der Ausführung mit deterministischen Tools validieren.

GLM-4.1V und Flash-Varianten sind für lokale Versuche realistischer als 108B-VLMs. Persischer Text in Bildern, RTL-Dokumente, Kleindruck und dichte Tabellen benötigen dennoch Oblivion-spezifische Tests.

OCR, Sprache, TTS und Bildgenerierung

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

OCR
Document structure

ASR / TTS
Speech input and output

IMAGE
Visual synthesis

AGENT
Computer interaction

Modell	Bereich	Technischer Hinweis
GLM-OCR	OCR / Dokumentverständnis	Etwa 0,9B, MIT; Vision Encoder und leichter Decoder. 94,62 OmniDocBench stammt aus dem Model Card.
GLM-ASR-Nano-2512	Spracherkennung	Etwa 1,5B; kompaktes ASR. Mit realen Sprachen und Mikrofonen testen.
GLM-TTS	Sprachsynthese	Speech Token plus Flow Matching. Voice Cloning braucht Zustimmung und Datenschutzkontrollen.
GLM-Image	Bildgenerierung und -bearbeitung	Hybride Architektur aus autoregressivem Modell und Diffusion; kein Chat-LLM.
AutoGLM / AutoGLM-Phone	GUI- und Mobile-Agenten	Beobachtung und Aktionen in Oberflächen; Freigabe, Begrenzung und Audit erforderlich.
GLM-4-Voice / GLM-Realtime	Sprache und Echtzeitinteraktion	Verwandte Produkt-/API-Zweige; tatsächliche Endpoint-Funktionen prüfen.

Kostenbewusste Wahl

Für PDF-Extraktion ist GLM-OCR oder eine spezialisierte OCR-Pipeline meist sinnvoller, als ganze Dokumente an ein 700B-Flaggschiff zu senden. Seitenreferenzen, Koordinaten und Confidence zusammen mit dem Text speichern.

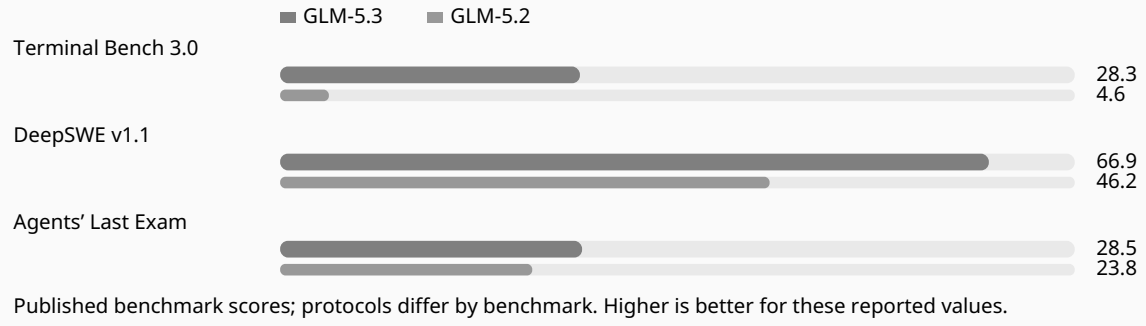
Sprachdatenschutz

Synthese oder Klonen nur mit expliziter, dokumentierter Erlaubnis der betreffenden Stimme. Roh-Audio und Voice Embeddings sind sensible Daten.

CogVideoX und andere Z.ai-Videogenerierungsprojekte gehören zum angrenzenden Portfolio. Ohne expliziten Beleg nicht als GLM-Modelle bezeichnen.

Herstellerangaben versus unabhängige Bewertung

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Von Oblivion anhand veröffentlichter Z.ai-Zahlen neu gezeichnet; kein unabhängig ausgeführter Benchmark.

Z.ai berichtet ausgewählte Verbesserungen von GLM-4.7 bei SWE-bench und Terminal-Bench. GLM-5.1 betont agentisches Coding, 5.2 den Ein-Million-Token-Kontext und 5.3 stärkeres Post-Training auf der 5.2-Basis. Für 5.3 nennt Z.ai eine Verbesserung von 50 Prozent im internen Code Bench; dies ist kein unabhängig reproduziertes Ergebnis.

Quelle	Berichtetes Ergebnis	Interpretationsgrenze
Z.ai · GLM-4.7	Verbesserungen bei SWE-bench und Terminal-Bench	Herstellerbewertung; Harness und Einstellungen relevant.
Z.ai · GLM-5.1	SWE-Bench Pro, NL2Repo, Terminal-Bench 2.0	Lange Workflows; mehrstündige Autonomie ist keine Garantie.
Z.ai · GLM-5.2	Ein-Million-Token-Kontext	Kontextlänge ist nicht gleich Retrieval-Genauigkeit oder geringe Latenz.
Z.ai · GLM-5.3	50 % besser als 5.2 im internen Code Bench	Internes Unternehmensergebnis, keine unabhängige Replikation.
NIST / CAISI · 17.09.2026	Starkes Open-Weight-Modell im Cyber-Test; im aggregierten Index etwa vier Monate hinter US-Frontier	Unabhängig, aber auf Cyber-Aufgaben begrenzt; kein Gesamtranking.

> **Wissenschaftlicher Maßstab**
>
> Jeder Score braucht Benchmark-Version, Harness, erlaubte Tools, Reasoning-Budget, Anzahl der Läufe, Erfolgskriterien und Unsicherheit. Inkompatible Provider-Leaderboards zu mitteln, ist nicht wissenschaftlich belastbar.

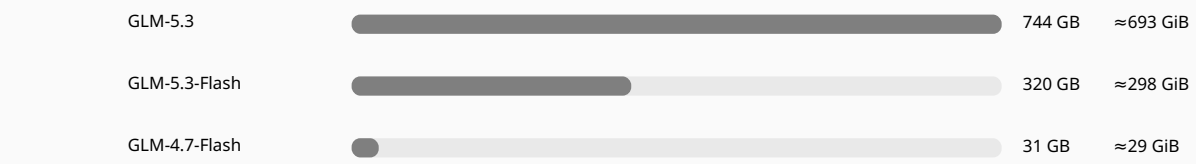
CAISI prüfte das Modell in einem festgelegten ReAct-Harness. Der Befund gilt für dieses Setup und nicht unverändert für jede Bereitstellung.

Open Weights bedeuten keine einfache lokale Ausführung

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Konzeptuelles Infrastrukturmotiv für die Erzählung; keine verifizierte Fotografie eines Z.ai-Rechenzentrums.



Einfache Schätzung mit einem Byte pro Gesamtparameter; ohne KV-Cache, Runtime, Sharding-Overhead und Aktivierungen.

GLM-5-Flaggschiffe enthalten Hunderte Milliarden Parameter. BF16-Gewichte benötigen Hunderte Gigabyte bis über ein Terabyte Rohspeicher. FP8 reduziert den Platzbedarf, das Modell bleibt jedoch sehr groß. Aktive Parameter beschreiben einen Teil des Token-Rechenaufwands, nicht den Speicher für sämtliche Gewichte.

Modell	Realität lokaler Ausführung	Praktische Empfehlung
GLM-5.3 / 5.2 / 5.1	Multi-GPU-Infrastruktur und ausgelegtes Serving nötig	Server oder Forschungscluster, kein typischer Laptop.
GLM-5.3-Flash	Trotz 18B aktiv etwa 320B gesamt	Kein lokales 18B-Modell; FP8-Gewichte rund 300GiB vor KV/ Runtime.
GLM-4.5-Air / 4.7	Große Rechenzentrums-Checkpoints	Quantisierung/Offload testen; Speicher und Latenz messen.
GLM-4.7-Flash	30B gesamt / 3B aktiv	Realistischer für quantisierte lokale Tests.
GLM-4.1V-9B / GLM-OCR	Relativ klein	Bessere Laptop-Kandidaten, abhängig von VRAM und Runtime.

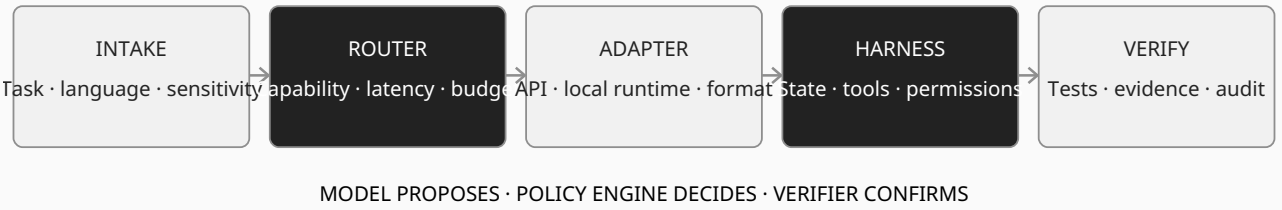
Vor dem Deployment messen

- Exakte Gewichtsdateigröße und Spitzen-VRAM/RAM
- Prefill-/Decode-Tokens pro Sekunde und Time-to-First-Token
- p50/p95-Latenz bei dokumentiertem Batch und Kontext
- Persischqualität, Tool-Fehlerrate und Kosten pro Aufgabe
- Stabilität bei langem Kontext und paralleler Last

> **Hardwareempfehlung für Oblivion**
>
> Auf einem Laptop der RTX-3060-Klasse ist die Ausführung vollständiger GLM-5.3- oder 5.3-Flash-Gewichte nicht realistisch. Lokal GLM-OCR, GLM-4.1V-9B und kleinere quantisierte Modelle testen; Flaggschiffe über API oder Multi-GPU-Server bereitstellen. Tatsächlichen VRAM-Bedarf und Checkpoint dokumentieren.

Unabhängiger Model Router und drei Kritikrunden

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Modellunabhängige Architektur für Oblivion

Aufgabe	Zu prüfender Kandidat	Begründung
Schwieriges Coding und Langzeitplanung	GLM-5.3	Hochwertiges Flaggschiff; große Infrastruktur.
Kostengünstigere Agenten	GLM-5.3-Flash / 5.1	Im eigenen Harness vergleichen; Flash bleibt insgesamt riesig.
Lokaler Text	GLM-4.7-Flash	Kleinerer Gesamt-Checkpoint; Quantisierung testen.
Bild und GUI	GLM-4.1V-9B / 4.6V Flash	Eigener Vision-Pfad.
PDF und Scans	GLM-OCR	Spezialmodell statt Text-Flaggschiff.
Sprache und Bilder	GLM-ASR / TTS / Image	Getrennte Module und Datenrichtlinien.

Drei Kritikrunden

Runde 1: Das neueste Modell ist nicht automatisch das beste; nach Aufgabe routen. **Runde 2:** 18B aktive Parameter bedeuten nicht 18B insgesamt; GLM-5.3-Flash hat etwa 320B gesamt. **Runde 3:** Agentische Fähigkeiten sind keine Sicherheitsgarantie. Regeln außerhalb des Modells erzwingen und Nebenwirkungen freigeben lassen.

> **Abschließende Empfehlung**
>
> GLM-5.3 als High-End-Engine für Reasoning und Coding bewerten; 5.3-Flash als große multimodale Infrastruktur statt Laptop-Modell behandeln; 4.7-Flash für lokale Tests sowie OCR/ASR/TTS/V für Spezialaufgaben prüfen. Das Modell schlägt Aktionen vor; ein unabhängiges Gateway entscheidet über Berechtigungen.

Protokoll vor der Veröffentlichung

1. 100–200 anonymisierte reale Aufgaben in mehreren Sprachen erstellen
2. Checkpoint, Quantisierung, Runtime, Prompt und Budget fixieren
3. Erfolgsquote, Tool-Fehler, Halluzinationen, Injection-Resistenz und Latenz messen
4. Instabile Aufgaben mindestens dreimal ausführen
5. Pareto-Kompromiss aus Qualität, Kosten, Geschwindigkeit und Risiko wählen

Umfang, Grenzen und Nachvollziehbarkeit

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

RESEARCH TRACEABILITY PRIMARY SOURCES · MODEL CARDS · TECHNICAL PAPERS

Dieser Bericht nutzt Z.ai Research, GitHub, Z.ai-Hugging-Face-Model-Cards, Herstellerunterlagen und die unabhängige CAISI/NIST-Bewertung. Hersteller-Benchmarks sind als Z.ai-Angaben markiert; NIST wird als unabhängige, auf Cyber-Aufgaben begrenzte Bewertung eingeordnet. Benchmarks wurden nicht unabhängig auf Oblivion-Hardware erneut ausgeführt. Dateigröße, Endpoint-Unterstützung, praktischer Kontext und Lizenz können nach Checkpoint, Anbieter und Runtime variieren.

Primärquellen

1. Z.ai Research Hub https://www.zhipuai.cn/en/research
2. Z.ai-Ankündigung GLM-5.3 https://z.ai/blog/glm-5.3
3. Offizielles GLM-5-Repository https://github.com/zai-org/GLM-5
4. Z.ai-Modellindex https://huggingface.co/zai-org/models
5. NVIDIA Model Card GLM-5.3-Flash https://build.nvidia.com/z-ai/glm-5-3-flash/modelcard
6. NIST / CAISI Cyber-Bewertung https://www.nist.gov/news-events/news/2026/09/caisis-assessment-zais-glm-53-cyber-capabilities
7. GLM-V-Repository https://github.com/zai-org/GLM-V
8. GLM-OCR-Repository https://github.com/zai-org/GLM-OCR
9. GLM-ASR-Nano-2512 https://huggingface.co/zai-org/GLM-ASR-Nano-2512
10. GLM-TTS-Repository https://github.com/zai-org/GLM-TTS
11. GLM-Image-Repository https://github.com/zai-org/GLM-Image
12. Technischer Bericht GLM-4.5 https://arxiv.org/abs/2508.06471
13. GLM-4.1V-Thinking-Paper https://arxiv.org/abs/2507.01006

> **Grenze des Fazits**
>
> Dies ist eine unabhängige Synthese öffentlicher Quellen, keine Sicherheitszertifizierung, kein reproduzierter Benchmark, keine Empfehlung von Z.ai und keine Eignungsgarantie für ein produktives Oblivion-System.

Für das Oblivion Engineering Team · Version 1.0