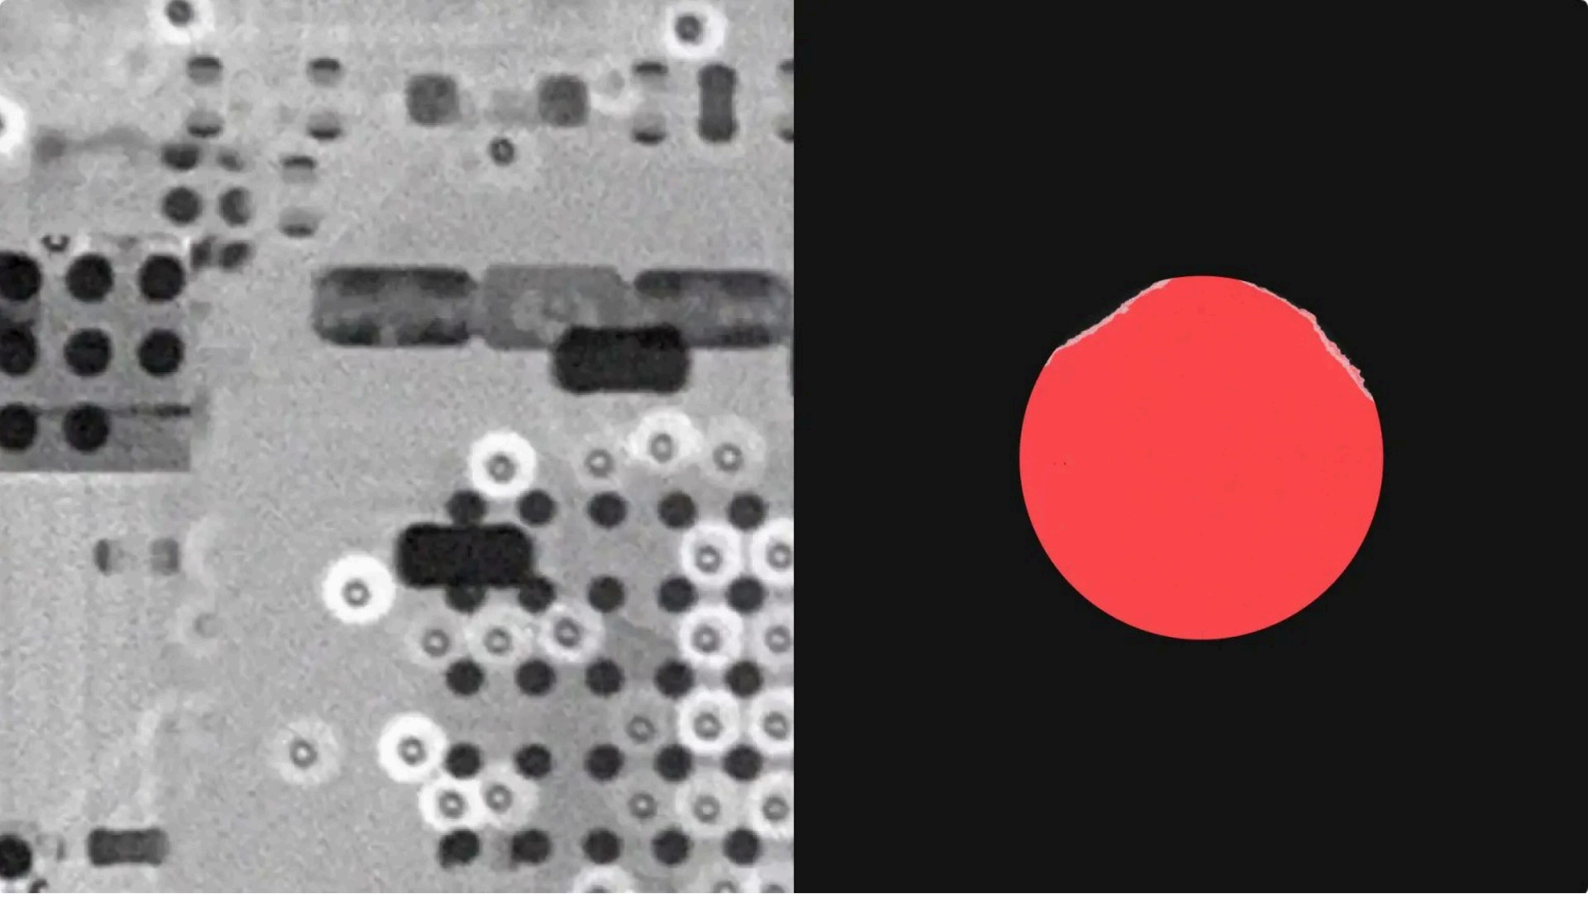


OBLIVION / TECHNICAL RESEARCH

GLMモデルファミリー

GLM-130Bから5.3と専門モデルまで、Z.aiモデルの技術レビュー

Oblivion向け技術調査・アーキテクチャ比較・批判的評価

2026年10月26日 | Research edition 1.1

GLMは単一モデルではなくモデル群である

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

GLMはAnthropicではなくZ.ai（旧Zhipu AI）のモデルファミリーです。初期の言語モデルから推論、Agentic Coding、Vision、OCR、音声、画像生成へ広がっています。異なる用途のモデルを単一の「知能スコア」やパラメータ数だけで比較することは適切ではありません。



レポートの導入用コンセプト画像。Z.aiデータセンターの実際の写真ではありません。

1M	744–753B	320B / 18B	0.9B
GLM-5.2 / 5.3の公称Context	GLM-5.3の報告総規模	5.3-Flashの総数 / 活性数	GLM-OCRの規模

Oblivionへの結論

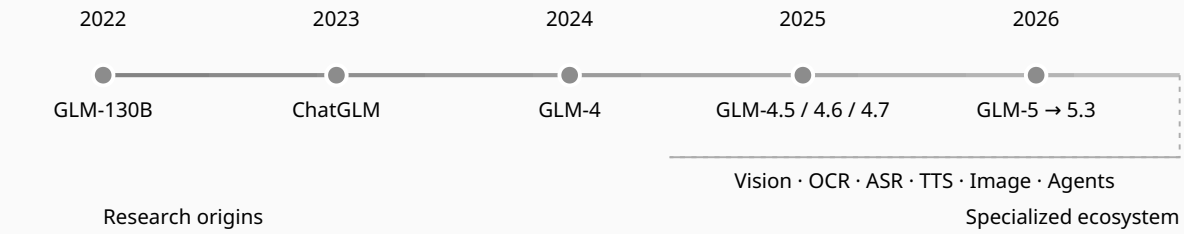
GLM-5.3は複雑なCodingと長期タスク向けのテキスト旗艦です。**GLM-5.3-Flash**は新しい基盤を持つマルチモーダル系で、18Bの軽量モデルではありません。制約のあるローカル環境では**GLM-4.7-Flash**や**GLM-OCR**のような専門モデルが現実的です。画像、文書、音声の処理は専用モデルへ振り分けます。

> **最終評価**
>
> GLMの強みは幅広い選択肢と公開重みです。課題は世代ごとの仕様差、大規模Checkpointの実コスト、Agent Harnessへの依存、Benchmark条件の不一致です。Oblivionは特定モデルに固定せず、独立したModel Routerを設計すべきです。

対象：2026年10月26日までに公開情報で確認できるZ.aiモデルと製品。API、公開重み、旧世代、関連製品を区別。

GLM-130Bからマルチモーダルファミリーへ

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



公開されているGLMファミリーの系譜に基づく図。専門モデルは後続章で分けて説明します。

GLMは**General Language Model**の略です。研究ファミリーは2022年にGLM-130Bで知られるようになりました。2023年のChatGLMは対話モデルを広げ、2024年のGLM-4は会話、視覚、ツール利用へ発展しました。現在のZ.aiは基盤モデル、API、完成したAgent製品を提供しています。

時期	代表モデル	正しい理解
2022	GLM-130B、GLM-10B	初期研究モデル。現行旗艦との直接比較には向かない。
2023	ChatGLM、ChatGLM2、ChatGLM3	対話型6B系。主に歴史的な位置づけ。
2024	GLM-4、GLM-4-9B、GLM-4V-9B、GLM-4-Voice	公開重み、Vision、音声へ拡張。
2025	GLM-4.5/Air、4.6、4.7、Vシリーズ	大規模MoE、Hybrid Reasoning、Agentic Coding。
2026	GLM-5、5.1、5.2、5.3、Flash	長期タスク、100万Token Context、新しいマルチモーダル。

> **「すべてのGLM」の範囲**
>
> 公開HubにはFP8/BF16、Base、専門Checkpointが多数あります。本レポートは識別できる公式ファミリーを扱い、すべての量子化版、第三者Fine-tune、Provider Aliasを別世代とは数えません。

GLM-4-Voice、GLM-Realtime、AutoGLM、GLM-PC、AutoGLM-Phoneは関連する製品／Agentシステムです。すべてをテキストLLMとみなすべきではありません。CogVideoXもZ.aiの関連製品ですが、自動的にGLMモデルになるわけではありません。

GLM-4.5からGLM-5.3まで

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

GLM-5.3

744B / 40B active

TEXT · LONG-HORIZON

Flagship

GLM-5.3-FLASH

320B / 18B active

MULTIMODAL · MoE

New base

GLM-4.7-FLASH

31B / 3B active

LOCAL TESTING

Compact family

公式Model Cardとリポジトリに基づく規模・アクティブパラメータ。アクティブ数は総重み容量を意味しません。

モデル	主な仕様	技術的役割
GLM-4.5	355B総数 / 32B活性、MoE	Agent、推論、Codingの基盤。Thinking / non-thinking。
GLM-4.5-Air	106B総数 / 12B活性	小型版だがノートPC級ではない。
GLM-4.6	約355B-A32B、最大200K	Coding、検索、Tool利用、Agent処理を改善。
GLM-4.7	約355B-A32B	一部Coding / Tool Benchmarkを改善。
GLM-4.7-Flash	約30B-A3B	小型テキスト系。量子化ローカル試験に比較的適する。
GLM-5	約744B / 40B活性、28.5T学習Token	複雑なシステム開発と長期Agentタスク。
GLM-5.1	Agentic Coding旗艦、文書上200K	多段階Coding向け。長時間実行はHarness依存。
GLM-5.2	100万Token Context	長期タスクと長文脈効率。
GLM-5.3	約744–753B / 40B活性、1M	5.2と同じBaseに強いPost-training。
GLM-5.3-Flash	320B総数 / 18B活性、1M	新Base、マルチモーダル。総数18Bではない。

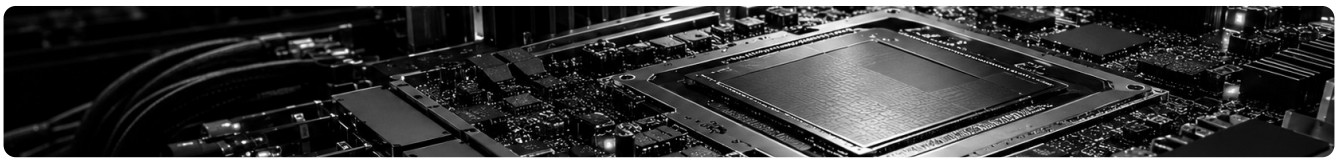
GLM-4.7-Flashが今も重要な理由

5.3-Flashより総Checkpointがかなり小さいため、制約環境でのAgentic Coding実験に向く可能性があります。ただし量子化とRuntimeを固定して実測が必要です。

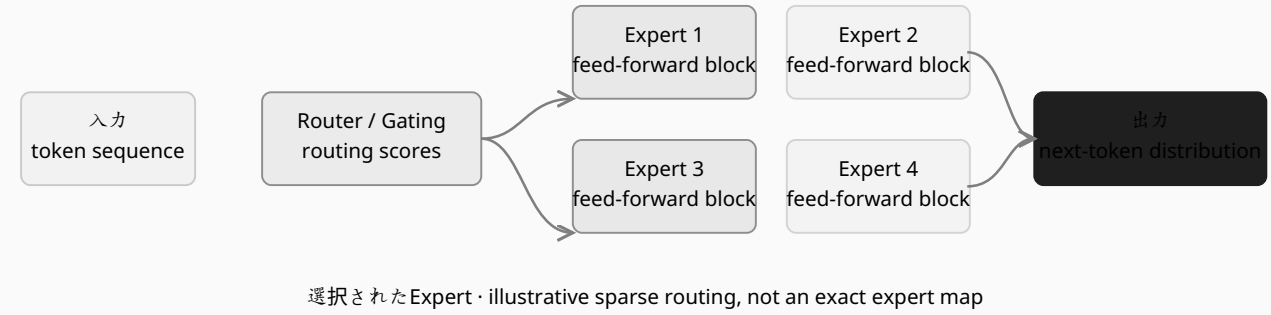
モデルID、Checkpoint日付、BF16/FP8、Context、License、Endpointをセットで記録してください。「latest」は時期やProviderにより変わる可能性があります。

MoE、Sparse Attention、長文脈

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



コンピューティング機器のコンセプト画像。マルチモーダル図は能力分類であり内部経路図ではありません。



GLM-5技術レポートを基に再設計した概念図です。全層の厳密な構成図ではありません。

GLM-4.5とGLM-5の旗艦は**Mixture-of-Experts**です。Routerは各Tokenで一部Expertだけを選び、Denseモデルに比べTokenごとの計算を減らします。しかし未選択ExpertもCheckpoint内に残るため、全重みをメモリまたはOffload経由で利用可能にする必要があります。

項目	GLM-5.3	GLM-5.3-Flash
総規模	README約744B、HF一覧753B	NVIDIA / HFで約320B
活性パラメータ	約40B	約18B
Context	Model Cardで1,048,576 Token	1M公称。全長の品質と速度は検証が必要
入力	テキスト	テキストと画像。VideoはEndpoint依存
主な違い	5.2 Baseと強化Post-training	新Base、30Tマルチモーダルデータ、Sparse + Linear Attention、mHC

Generation 5の技術

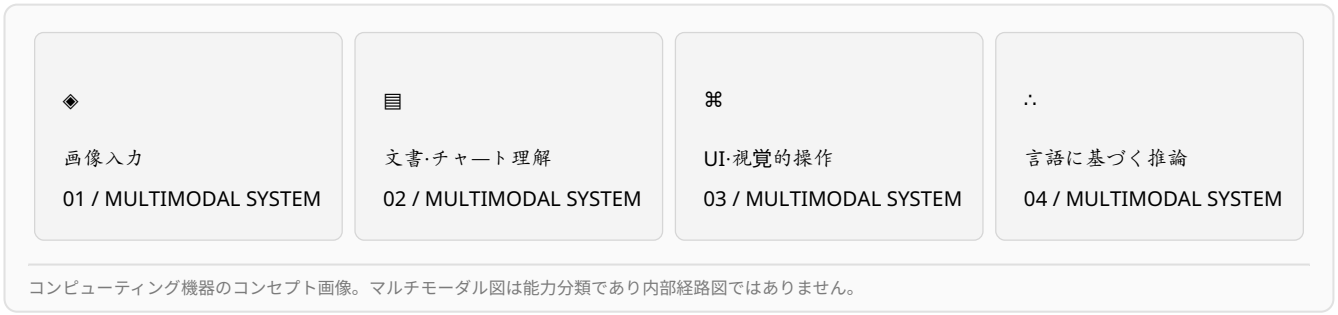
- **DSA:** 全TokenへのDense Attentionではなく、長文脈の関連部分を選択。
- **IndexShare:** 5.2の一部LayerでIndexerを共有。2.9×削減はZ.aiの条件付き報告値。
- **Hybrid Attention:** 5.3-FlashはSparseとLinearを組み合わせ、長文脈Servingコストを下げる。
- **mHC / MTP:** Hyper-ConnectionsとMulti-Token Predictionによる拡張。

> **容量を性能と混同しない**
> 1M Contextは全長で安価・高速・正確に動く証明ではありません。Throughput、遠距離情報の取得、KV Cache、Batch、Memoryを別々に測定してください。

GLM-5.3の744B/753Bの差は公開ArtifactとModel Cardのカウント方式によるものです。レポートは両方を示します。

GLM-VとGLM-5V-Turbo

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



コンピューティング機器のコンセプト画像。マルチモーダル図は能力分類であり内部経路図ではありません。

モデル	規模 / 世代	用途
GLM-4.1V-9B-Thinking	約9B、64K	画像、Chart、文書の視覚推論。
GLM-4.5V	約108B	画像・動画・文書、Visual Grounding、GUI。
GLM-4.6V	約108B、Flash約9–10B	画像とテキストの混在、長文書、Chart、UI再現。
GLM-5V-Turbo	APIマルチモーダルCoding基盤	テキスト、画像、動画、ファイル入力。視覚CodingとGUI。
GLM-5.3-Flash	320B総数 / 18B活性	Z.aiによるGLM-5初のNative Multimodal。テキストと画像。

Visionモデルの用途

- Screenshot、Chart、UIレイアウトの理解
- スキャン文書からの情報抽出
- 画像を根拠とするUIコード生成
- Endpointが明示的に対応する場合の動画／Frame分析

> **Oblivion向け実装**
>
> 元画像、寸法、Crop、事前OCR、ソースファイルを保存し、入力を追跡可能にします。クリックやファイル変更は決定論的ツールで実行前に検証してください。

GLM-4.1VやFlashは108B VLMよりローカル試験に現実的です。ただしペルシャ語画像、RTL文書、小さな文字、複雑な表は独自データで評価する必要があります。

OCR、音声、TTS、画像生成

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

OCR
Document structure

ASR / TTS
Speech input and output

IMAGE
Visual synthesis

AGENT
Computer interaction

モデル	領域	技術的注意
GLM-OCR	OCR / 文書理解	約0.9B、MIT。Vision Encoderと軽量Decoder。94.62 OmniDocBenchはModel Cardの値。
GLM-ASR-Nano-2512	音声認識	約1.5B。小型ASR。実際の言語とマイクで検証。
GLM-TTS	音声合成	Speech Token + Flow Matching。Voice Cloningには同意とプライバシー制御が必要。
GLM-Image	画像生成・編集	AutoregressiveとDiffusionのHybrid。会話型LLMではない。
AutoGLM / AutoGLM-Phone	GUI / モバイルAgent	画面の観察と操作。人間承認、範囲制限、Auditが必要。
GLM-4-Voice / GLM-Realtime	音声・リアルタイム	関連する旧製品/API系統。Endpointごとに機能を確認。

コスト効率の良い選択

PDF抽出では700B旗艦に文書を丸ごと渡すより、GLM-OCRや専用OCRが合理的です。抽出文とページ参照、座標、Confidenceを保存してください。

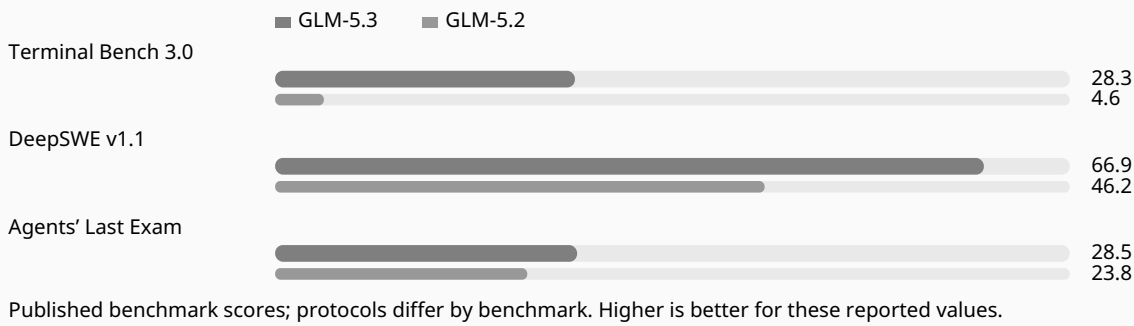
音声プライバシー

音声生成・複製は明示的な許可を得た声だけにしてください。Raw AudioとVoice Embeddingは機微情報です。

CogVideoXなどの動画生成はZ.aiの関連製品ですが、明示的な出典なしにGLMと呼ばないでください。

メーカー主張と独立評価

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Z.ai公開データを基にOblivionが再構成した図であり、独立したベンチマーク実行ではありません。

Z.aiはGLM-4.7のSWE-bench、Terminal-Bench等の改善を報告しました。5.1はAgentic Coding、5.2は1M Context、5.3は5.2 Baseへの追加Post-trainingを強調します。5.3について、社内Code Benchで50%改善という主張がありますが、これは独立再現ではありません。

出典	報告内容	解釈上の制限
Z.ai · GLM-4.7	SWE-bench / Terminal-Benchの改善	メーカー評価。Harnessと設定に依存。
Z.ai · GLM-5.1	SWE-Bench Pro、NL2Repo、Terminal-Bench 2.0	長いWorkflow。数時間の自律性は保証ではない。
Z.ai · GLM-5.2	100万Token Context	Context長は検索精度や低Latencyと同じではない。
Z.ai · GLM-5.3	内部Code Benchで5.2比50%改善	社内結果。独立した再現ではない。
NIST / CAISI · 2026-09-17	Cyber評価で強いOpen-weightモデル。集約指標で米国Frontierより約4か月遅れ	独立評価だがCyber領域限定。全能力の順位ではない。

科学的な基準

スコアにはBenchmarkのVersion、Harness、ツール、Reasoning予算、試行回数、成功条件、不確実性を記録します。異なる条件のProvider順位を平均しても妥当な評価にはなりません。

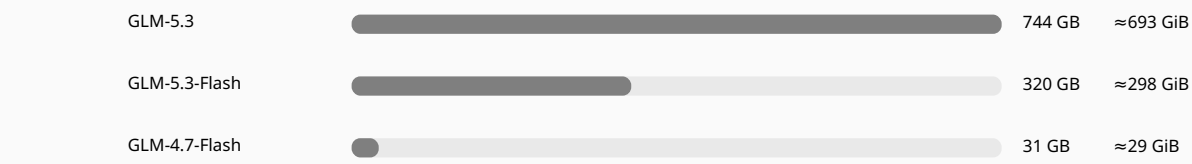
CAISIは指定されたReAct HarnessでAgentを評価しました。結果はその環境に関するもので、すべてのDeploymentに共通する固定値ではありません。

Open-weightでもローカル実行は簡単ではない

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



レポートの導入用コンセプト画像。Z.aiデータセンターの実際の写真ではありません。



総パラメータ数×1バイトの単純推定。KV cache、runtime、sharding、activationは含みません。

GLM-5旗艦は数千億パラメータです。BF16重みは数百GBから1TB超の生メモリを必要とします。FP8で縮小しても大規模です。活性パラメータはToken計算量の一部であり、全重みの保存メモリではありません。

モデル	ローカル実行の現実	実務上の提案
GLM-5.3 / 5.2 / 5.1	Multi-GPUとServing設計が必要	サーバー／研究環境向け。通常のLaptopではない。
GLM-5.3-Flash	18B活性でも総数約320B	18Bローカルモデルではない。FP8重みはKV前で約300GiBとの報告。
GLM-4.5-Air / 4.7	大規模Data Center級	量子化やOffload後もMemoryとLatencyを測定。
GLM-4.7-Flash	30B総数 / 3B活性	量子化ローカル試験に比較的適する。
GLM-4.1V-9B / GLM-OCR	比較的小型	実際のVRAMとRuntime次第でLaptop試験候補。

導入前に測定

- 重みファイルの容量と最大VRAM/RAM
- Prefill/Decode tokens/secとTTFT
- Batch/Contextを明示したp50/p95 latency
- ペルシャ語品質、Toolエラー、タスク単価
- 長文脈と並列負荷での安定性

> **Oblivionのハードウェア提案**
>
> RTX 3060クラスのLaptopではGLM-5.3または5.3-Flashの全重み実行は現実的ではありません。ローカルではGLM-OCR、GLM-4.1V-9B、小型量子化モデルを試し、旗艦はAPIまたはMulti-GPUサーバーで提供してください。VRAMとCheckpointを明記します。

Model Routerと3回の批判・修正

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



MODEL PROPOSES · POLICY ENGINE DECIDES · VERIFIER CONFIRMS

Oblivion向けモデル非依存アーキテクチャ

用途	評価候補	理由
難しいCodingと長期計画	GLM-5.3	高性能旗艦。大規模インフラ。
低コストAgent	GLM-5.3-Flash / 5.1	自社Harnessで比較。Flashも総重みは巨大。
ローカルテキスト	GLM-4.7-Flash	総Checkpointが小さい。量子化を検証。
画像とGUI	GLM-4.1V-9B / 4.6V Flash	専用Vision経路。
PDFとスキャン	GLM-OCR	テキスト旗艦より専門モデル。
音声・画像	GLM-ASR / TTS / Image	独立モジュールとデータポリシー。

3回の批判

第1回: 最新が常に最善とは限らない。タスクで選ぶ。**第2回:** 5.3-Flashの18B活性は18B総数を意味せず、総数は約320B。**第3回:** Agent性能は安全保証ではない。Policyはモデル外で強制し、Side Effectには承認を求める。

> **最終提案**
> GLM-5.3は高度なReasoning/Coding向けに評価。5.3-Flashは大型マルチモーダル基盤でありLaptop用ではない。ローカル試験に4.7-Flash、専門作業にOCR/ASR/TTS/Vを検討します。モデルはActionを提案し、独立Gatewayが権限を判断します。

公開前の評価

1. 匿名化した実タスクを多言語で100〜200件作成
2. Checkpoint、量子化、Runtime、Prompt、Budgetを固定
3. Pass率、Toolエラー、Hallucination、Injection耐性、Latencyを測定
4. 不安定なタスクは3回以上実行
5. 品質・コスト・速度・リスクのPareto点を選択

調査範囲、制限、追跡可能性

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

RESEARCH TRACEABILITY PRIMARY SOURCES · MODEL CARDS · TECHNICAL PAPERS

本レポートはZ.ai Research、GitHub、Hugging FaceのZ.ai Model Card、メーカー資料、CAISI/NISTの独立評価を利用しています。メーカーBenchmarkは「Z.ai報告値」とし、NISTはCyber領域に限定された独立評価としています。Oblivionハードウェアでの独立再実行は行っていません。Checkpoint、Provider、Runtimeで容量やEndpoint、ライセンスが異なる可能性があります。

主な一次資料

1. Z.ai Research Hub https://www.zhipuai.cn/en/research
2. Z.ai GLM-5.3 announcement https://z.ai/blog/glm-5.3
3. GLM-5 repository https://github.com/zai-org/GLM-5
4. Z.ai model index https://huggingface.co/zai-org/models
5. NVIDIA GLM-5.3-Flash model card https://build.nvidia.com/z-ai/glm-5-3-flash/modelcard
6. NIST / CAISI cyber assessment https://www.nist.gov/news-events/news/2026/09/caisis-assessment-zais-glm-53-cyber-capabilities
7. GLM-V https://github.com/zai-org/GLM-V
8. GLM-OCR https://github.com/zai-org/GLM-OCR
9. GLM-ASR-Nano-2512 https://huggingface.co/zai-org/GLM-ASR-Nano-2512
10. GLM-TTS https://github.com/zai-org/GLM-TTS
11. GLM-Image https://github.com/zai-org/GLM-Image
12. GLM-4.5 technical report https://arxiv.org/abs/2508.06471
13. GLM-4.1V-Thinking paper https://arxiv.org/abs/2507.01006

> **結論の範囲**
>
> これは公開資料に基づく調査統合であり、セキュリティ認証、再現済みBenchmark、Z.aiの推薦、Oblivion本番システムへの適合保証ではありません。

Oblivionエンジニアリングチーム向け・Version 1.0