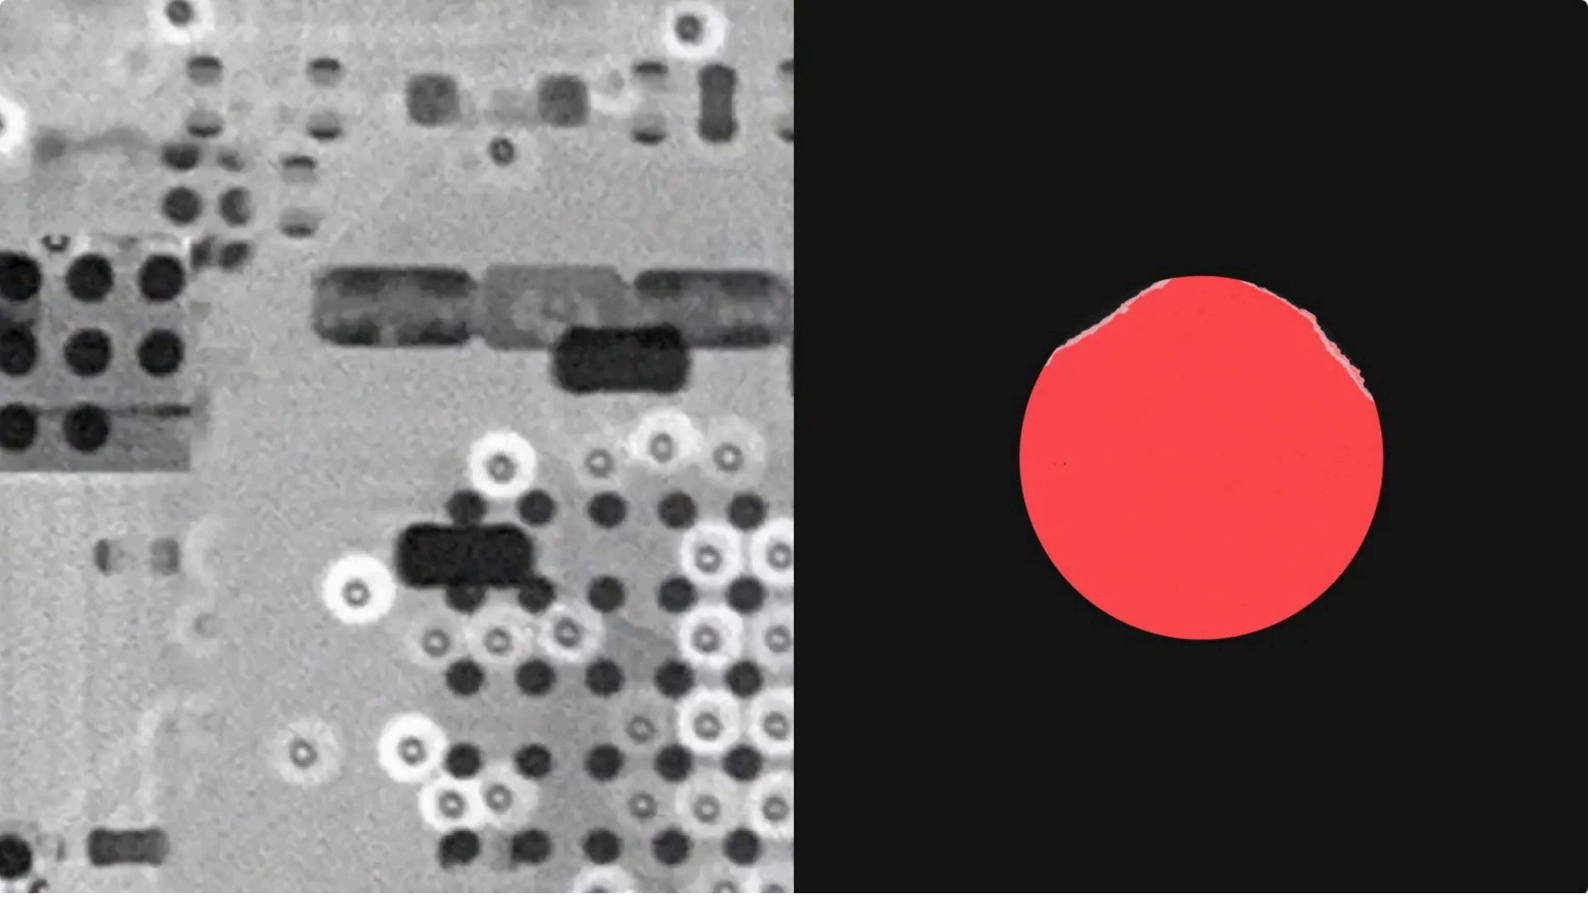


OBLIVION / TECHNICAL RESEARCH

GLM 모델 패밀리

GLM-130B부터 5.3 및 전문 모델까지 Z.ai 모델 기술 검토

Oblivion을 위한 엔지니어링 연구 · 아키텍처 비교 · 비판적 평가

2026년 10월 26일 | Research edition 1.1

GLM은 단일 모델이 아니라 모델 패밀리다

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

GLM은 Anthropic이 아니라 Z.ai(구 Zhipu AI)의 모델 패밀리다. 사전학습 언어모델에서 추론, 에이전트 코딩, 비전, OCR, 음성, 이미지 생성으로 확장됐다. 서로 다른 전문 분야를 하나의 지능 점수나 파라미터 수만으로 비교하는 것은 기술적으로 타당하지 않다.



보고서 서사를 위한 인프라 콘셉트 이미지이며 Z.ai 데이터센터의 실제 사진이 아닙니다.

1M	744–753B	320B / 18B	0.9B
GLM-5.2 / 5.3 명목 컨텍스트	GLM-5.3 총 파라미터 보고치	GLM-5.3-Flash 총량 / 활성	GLM-OCR 대략적 크기

Oblivion 엔지니어링 결론

GLM-5.3은 복잡한 코딩과 장기 작업을 위한 텍스트 플래그십이다. **GLM-5.3-Flash**는 새 기반의 멀티모달 계열이지 18B 경량 모델이 아니다. 제한된 로컬 장비에서는 **GLM-4.7-Flash**와 **GLM-OCR** 같은 소형 전문 모델이 더 현실적인 출발점이다.

> **최종 판단**
>
> GLM의 강점은 폭넓은 모델군과 공개 가중치 접근성이다. 반면 버전의 이질성, 대형 체크포인트의 실제 비용, Agent Harness 의존성, 벤치마크 조건 차이가 문제다. Oblivion은 특정 모델명에 종속되지 않는 Model Router를 구축해야 한다.

범위: 2026년 10월 26일까지 공개적으로 추적 가능한 Z.ai 모델과 제품. API, 공개 가중치, 과거 모델 및 인접 제품을 구분한다.

GLM-130B에서 멀티모달 패밀리까지

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



공개된 GLM 패밀리 계보를 바탕으로 구성했으며 전문 모델 분기는 뒤 장에서 구분합니다.

GLM은 **General Language Model**의 약자다. 연구 계보는 2022년 GLM-130B로 알려졌고, 2023년 ChatGLM이 대화형 모델을 확장했다. 2024년 GLM-4는 대화, 비전, 도구 사용으로 범위를 넓혔다. 오늘날 Z.ai 포트폴리오에는 기반 모델, API, 완성형 에이전트 시스템이 함께 존재한다.

시기	대표 모델	올바른 해석
2022	GLM-130B, GLM-10B	초기 연구 모델. 현세대 플래그십과 직접 비교하기 어렵다.
2023	ChatGLM, ChatGLM2, ChatGLM3	대화형 6B 계열. 역사적 맥락이 중요하다.
2024	GLM-4, GLM-4-9B, GLM-4V-9B, GLM-4-Voice	공개 가중치, 비전, 음성으로 확장.
2025	GLM-4.5/Air, 4.6, 4.7, V 계열	대형 MoE, 하이브리드 추론, 에이전트 코딩.
2026	GLM-5, 5.1, 5.2, 5.3, Flash	장기 작업, 100만 토큰 컨텍스트, 멀티모달.

> **"모든 GLM"의 범위**
>
> 공개 허브에는 BF16/FP8, Base 및 전문 체크포인트가 다수 존재한다. 본 보고서는 식별 가능한 공식 패밀리를 다루며, 모든 양자화 버전이나 제3자 파인튜닝·Provider Alias를 별도 세대로 세지 않는다.

GLM-4-Voice, GLM-Realtime, AutoGLM, GLM-PC, AutoGLM-Phone은 관련 제품 또는 에이전트 시스템이다. 모두를 텍스트 LLM으로 분류해서는 안 된다. CogVideoX도 Z.ai의 인접 제품이지만 자동으로 GLM 모델이 되는 것은 아니다.

GLM-4.5부터 GLM-5.3까지

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

GLM-5.3

744B / 40B active

TEXT · LONG-HORIZON

Flagship

GLM-5.3-FLASH

320B / 18B active

MULTIMODAL · MoE

New base

GLM-4.7-FLASH

31B / 3B active

LOCAL TESTING

Compact family

공식 모델 카드와 저장소의 모델 크기 및 활성 파라미터입니다. 활성 파라미터는 전체 가중치 용량이 아닙니다.

모델	주요 사양	엔지니어링 역할
GLM-4.5	총 355B / 활성 32B, MoE	에이전트·추론·코딩 기반, Thinking / non-thinking.
GLM-4.5-Air	총 106B / 활성 12B	작은 형제 모델이지만 노트북급은 아니다.
GLM-4.6	약 355B-A32B, 최대 200K	코딩, 검색, 도구 사용, 에이전트 워크플로 개선.
GLM-4.7	약 355B-A32B	일부 코딩 및 도구 벤치마크 개선.
GLM-4.7-Flash	약 30B-A3B	작은 텍스트 계열, 양자화 로컬 시험에 상대적으로 적합.
GLM-5	약 744B / 활성 40B, 학습 28.5T 토큰	복잡한 시스템 개발과 장기 에이전트 작업.
GLM-5.1	에이전트 코딩 플래그십, 문서상 200K	다단계 코딩. 장시간 자율 실행은 Harness에 의존.
GLM-5.2	100만 토큰 컨텍스트	장기 작업과 긴 컨텍스트 효율.
GLM-5.3	약 744-753B / 활성 40B, 1M	5.2와 같은 Base에 강화된 후처리 학습.
GLM-5.3-Flash	총 320B / 활성 18B, 1M	새 Base 및 멀티모달. Flash는 총 18B라는 뜻이 아니다.

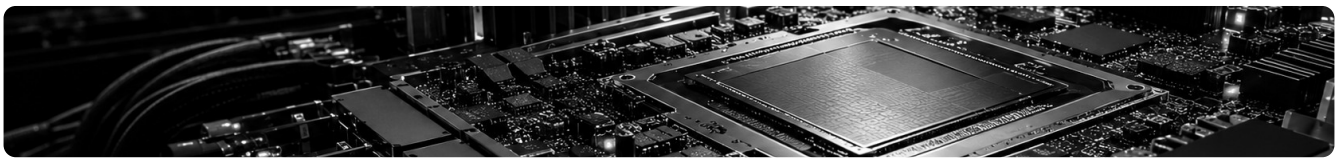
GLM-4.7-Flash가 여전히 중요한 이유

총 체크포인트가 5.3-Flash보다 훨씬 작다. 제한된 장비의 에이전트 코딩 실험에서 더 실용적인 시작점일 수 있지만, 고정된 양자화와 런타임에서 품질·메모리·속도를 측정해야 한다.

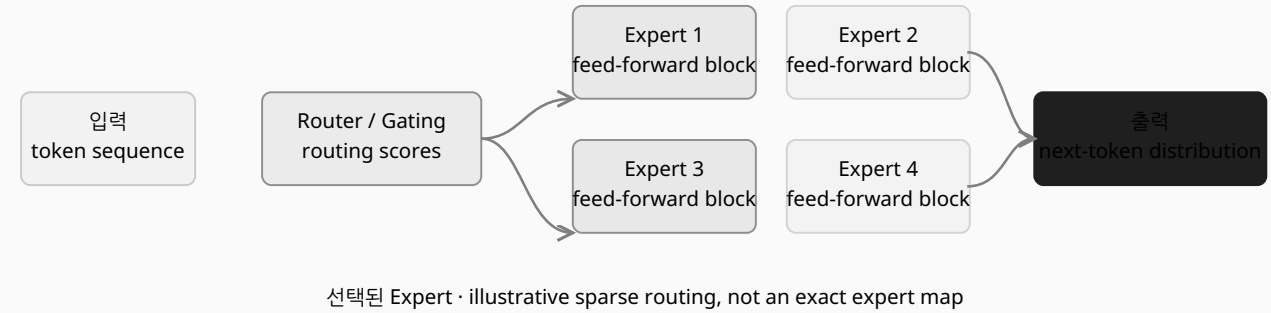
모델 ID, 체크포인트 날짜, BF16/FP8 형식, 컨텍스트, 라이선스, 엔드포인트를 함께 기록한다. “latest” 별칭은 시간과 제공자에 따라 달라질 수 있다.

MoE, Sparse Attention, 장문 컨텍스트

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



컴퓨팅 하드웨어 콘셉트 이미지이며 멀티모달 도식은 내부 경로가 아닌 기능 분류입니다.



GLM-5 기술 보고서를 바탕으로 재구성한 개념도이며 실제 모든 레이어의 상세 구조도는 아닙니다.

GLM-4.5와 GLM-5 플래그십은 **Mixture-of-Experts** 구조를 사용한다. Router는 토큰마다 일부 전문가만 활성화해 계산량을 줄인다. 그러나 비활성 전문가도 체크포인트에 남아 있으므로 전체 가중치는 메모리 또는 Offload 경로로 접근 가능해야 한다.

항목	GLM-5.3	GLM-5.3-Flash
총 규모	README 약 744B, HF 목록 753B	NVIDIA / HF 약 320B
활성 파라미터	약 40B	약 18B
컨텍스트	Model Card 1,048,576 토큰	공칭 1M; 전체 길이 품질과 처리량 검증 필요
입력	텍스트	텍스트와 이미지; 동영상은 Endpoint에 따름
핵심 차이	5.2 Base와 강화된 Post-training	새 Base, 30T 멀티모달 토큰, Sparse + Linear Attention, mHC

Generation 5 메커니즘

- **DSA:** 모든 토큰에 Dense Attention을 적용하기보다 긴 문맥에서 관련 부분을 선택.
- **IndexShare:** 5.2의 일부 계층에서 Indexer 공유. 2.9배 FLOPs 감소는 특정 조건의 제조사 보고치.
- **Hybrid Attention:** 5.3-Flash에서 Sparse와 Linear 경로를 결합해 장문맥 Serving 비용을 줄임.
- **mHC / MTP:** Hyper-Connections와 Multi-Token Prediction으로 확장성과 speculative decoding 지원.

> **컨텍스트 한도를 성능으로 오해하지 말 것**
>
> 1M 토큰 한도는 전체 길이에서 빠르고 저렴하며 정확하게 동작한다는 증거가 아니다. 처리량, 먼 정보 검색, KV Cache, Batch, 메모리를 별도로 측정해야 한다.

GLM-5.3은 공개 Artifact와 Model Card 방식에 따라 744B와 753B가 모두 표기된다. 본 보고서는 두 값을 모두 남긴다.

GLM-V와 GLM-5V-Turbo

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



모델	규모 / 세대	목표 기능
GLM-4.1V-9B-Thinking	약 9B, 64K	이미지·차트·문서의 시각적 추론.
GLM-4.5V	약 108B	이미지, 동영상, 문서, Visual Grounding, GUI.
GLM-4.6V	약 108B, Flash 약 9-10B	이미지-텍스트 혼합, 장문서, 차트, UI 재현.
GLM-5V-Turbo	API 멀티모달 코딩 기반	텍스트·이미지·동영상·파일 입력, 시각 코딩과 GUI.
GLM-5.3-Flash	총 320B / 활성 18B	Z.ai에 따르면 GLM-5 최초의 Native Multimodal 모델; 텍스트와 이미지.

실제 비전 사용 사례

- 스크린샷, 차트, UI 레이아웃 이해
- 스캔 문서 정보 추출
- 시각적 근거를 UI 코드로 변환
- Endpoint가 명시적으로 지원하는 경우 동영상/프레임 분석

> **Oblivion 구현 가이드**
>
> 원본 이미지, 크기, Crop, 사전 OCR, 소스 파일을 보존한다. 클릭이나 파일 변경을 제안하는 경우 실행 전에 결정론적 도구로 검증한다.

GLM-4.1V와 Flash 변형은 108B VLM보다 로컬 실험에 현실적이다. 다만 이미지 속 페르시아어, RTL 문서, 작은 글씨, 복잡한 표는 Oblivion 자체 데이터로 시험해야 한다.

OCR, 음성, TTS, 이미지 생성

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

OCR
Document structure

ASR / TTS
Speech input and output

IMAGE
Visual synthesis

AGENT
Computer interaction

모델	분야	기술적 유의점
GLM-OCR	OCR / 문서 이해	약 0.9B, MIT. Vision Encoder와 경량 Decoder. 94.62 OmniDocBench는 Model Card 값.
GLM-ASR-Nano-2512	음성 인식	약 1.5B, 소형 ASR. 실제 언어와 마이크 환경에서 검증.
GLM-TTS	음성 합성	Speech Token + Flow Matching. Voice Cloning은 동의와 개인정보 통제가 필요.
GLM-Image	이미지 생성 및 편집	Autoregressive + Diffusion 하이브리드. 대화형 LLM이 아니다.
AutoGLM / AutoGLM-Phone	GUI / 모바일 Agent	화면 관찰과 동작. 사람 승인, 범위 제한, Audit 필요.
GLM-4-Voice / GLM-Realtime	음성 / 실시간 상호작용	관련 구형 제품/API 계열. Endpoint별 기능 확인.

비용 효율적 선택

PDF 추출에는 700B 플래그십보다 GLM-OCR 또는 전문 OCR 파이프라인이 합리적이다. 추출 텍스트와 페이지 참조, 좌표, Confidence를 함께 저장한다.

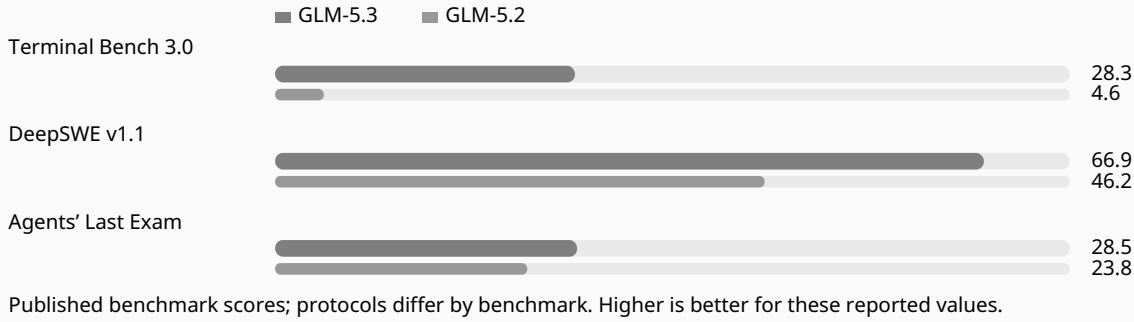
음성 프라이버시

합성이나 복제에는 명시적 허가가 있는 음성만 사용한다. 원시 오디오와 Voice Embedding은 민감 데이터다.

CogVideoX 등 Z.ai의 동영상 생성 제품은 인접 포트폴리오다. 명시적 출처 없이 GLM 모델로 부르지 않는다.

제조사 주장과 독립 평가

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Z.ai 공개 수치를 바탕으로 Oblivion이 다시 그린 차트이며 독립 벤치마크 실행 결과가 아닙니다.

Z.ai는 GLM-4.7의 SWE-bench와 Terminal-Bench 개선을 보고했다. 5.1은 Agentic Coding, 5.2는 1M 컨텍스트, 5.3은 5.2 Base에 대한 강화된 Post-training을 강조한다. 5.3의 Code Bench 50% 개선은 Z.ai 내부 결과이며 독립 재현 결과가 아니다.

출처	보고된 결과	해석의 한계
Z.ai · GLM-4.7	SWE-bench 및 Terminal-Bench 개선	제조사 평가. Harness와 설정에 의존.
Z.ai · GLM-5.1	SWE-Bench Pro, NL2Repo, Terminal-Bench 2.0	긴 워크플로. 수 시간 자율 실행은 보장되지 않는다.
Z.ai · GLM-5.2	100만 토큰 컨텍스트	긴 컨텍스트는 검색 정확도나 낮은 지연과 같지 않다.
Z.ai · GLM-5.3	내부 Code Bench에서 5.2 대비 50% 개선	회사 내부 결과, 독립 재현 아님.
NIST / CAISI · 2026-09-17	Cyber 평가군에서 강한 Open-weight 모델; 종합 지표상 미국 Frontier보다 약 4개월 뒤처짐	독립 평가이나 사이버 범위 한정. 전체 능력 순위가 아니다.

> **과학적 기준**
>
> 점수에는 Benchmark 버전, Harness, 허용 도구, 추론 예산, 반복 횟수, 성공 조건, 불확실성을 기록한다. 서로 다른 조건의 제공자 순위를 평균 내는 것은 타당하지 않다.

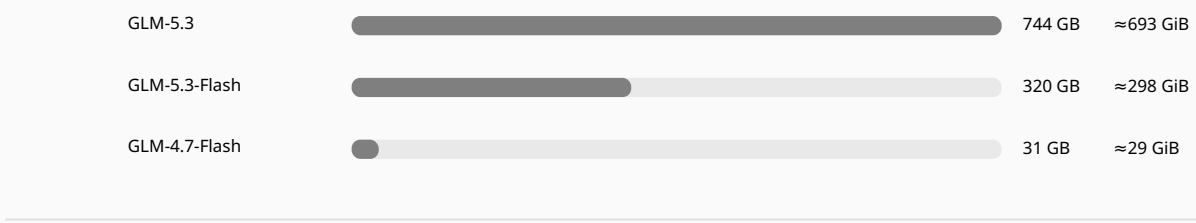
CAISI는 지정된 ReAct Harness에서 모델을 평가했다. 결과는 해당 설정에 적용되며 모든 배포 환경의 고정된 속성이 아니다.

Open-weight가 쉬운 로컬 실행을 뜻하지는 않는다

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



보고서 서사를 위한 인프라 콘셉트 이미지이며 Z.ai 데이터센터의 실제 사진이 아닙니다.



전체 파라미터당 1바이트를 적용한 단순 추정이며 KV cache, runtime, sharding 및 activation은 제외합니다.

GLM-5 플래그십은 수천억 파라미터다. BF16 가중치는 수백 GB에서 1TB 이상의 원시 메모리를 요구한다. FP8은 크기를 줄이지만 여전히 거대하다. 활성 파라미터는 토큰 계산량의 일부이지 모든 가중치를 위한 메모리가 아니다.

모델	로컬 실행 현실	실무 제안
GLM-5.3 / 5.2 / 5.1	Multi-GPU와 설계된 Serving 필요	서버/연구 환경용. 일반 노트북용 아님.
GLM-5.3-Flash	활성 18B여도 총량 약 320B	18B 로컬 모델이 아니다. FP8 가중치 약 300GiB, KV/Runtime 전.
GLM-4.5-Air / 4.7	대형 데이터센터급 체크포인트	양자화/Offload를 시험하고 메모리·지연을 측정.
GLM-4.7-Flash	총 30B / 활성 3B	양자화 로컬 실험에 더 현실적.
GLM-4.1V-9B / GLM-OCR	상대적으로 소형	실제 VRAM과 Runtime 조건부로 노트북 후보.

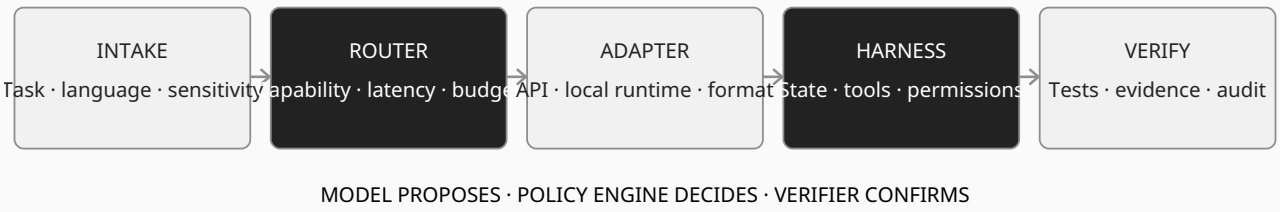
배포 전 측정 항목

- 정확한 가중치 파일 크기와 최대 VRAM/RAM
- Prefill/Decode tokens/sec, 첫 토큰 시간
- 명시된 Batch와 Context에서 p50/p95 지연
- 페르시아어 품질, 도구 오류율, 작업당 비용
- 장문맥 및 동시 부하에서의 안정성

> **Oblivion 하드웨어 제안**
>
> RTX 3060급 노트북에서 GLM-5.3 또는 5.3-Flash 전체 가중치 실행은 현실적이지 않다. 로컬에는 GLM-OCR, GLM-4.1V-9B, 소형 양자화 모델을 시험하고 플래그십은 API 또는 Multi-GPU 서버에서 제공한다. 실제 VRAM과 체크포인트를 기록한다.

독립 Model Router와 세 차례 비판

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH



Oblivion을 위한 모델 독립형 아키텍처

업무	평가 후보	이유
어려운 코딩·장기 계획	GLM-5.3	고성능 플래그십. 대형 인프라.
저비용 에이전트	GLM-5.3-Flash / 5.1	자체 Harness로 비교. Flash도 총 가중치는 거대.
로컬 텍스트	GLM-4.7-Flash	작은 총 체크포인트. 양자화 검증.
이미지 및 GUI	GLM-4.1V-9B / 4.6V Flash	전용 비전 경로.
PDF 및 스캔	GLM-OCR	텍스트 플래그십 대신 전문 모델.
음성 및 이미지	GLM-ASR / TTS / Image	별도 모듈과 데이터 정책.

세 차례 비판

1차: 최신이 항상 최선은 아니다. 작업별로 선택한다. **2차:** 5.3-Flash의 활성 18B는 총 18B가 아니며 총량은 약 320B다. **3차:** Agentic 능력은 보안 보장이 아니다. Policy는 모델 외부에서 강제하고 부작용에는 승인을 요구한다.

> **Oblivion 최종 권고**
>
> GLM-5.3은 고급 추론/코딩 엔진으로 평가하고, 5.3-Flash는 노트북 모델이 아닌 대형 멀티모달 인프라로 취급한다. 로컬 시험에는 4.7-Flash, 전문 업무에는 OCR/ASR/TTS/V를 검토한다. 모델은 동작을 제안하고 독립 Gateway가 권한을 결정한다.

출시 전 프로토콜

1. 익명화한 실제 다국어 작업 100~200개 생성
2. 체크포인트, 양자화, 런타임, 프롬프트, 예산 고정
3. 성공률, 도구 오류, 환각, Injection 저항성, 지연 측정
4. 불안정한 작업은 최소 3회 반복
5. 품질·비용·속도·위험의 Pareto 균형 선택

범위, 한계, 추적 가능성

THE GLM MODEL FAMILY · OBLIVION TECHNICAL RESEARCH

RESEARCH TRACEABILITY PRIMARY SOURCES · MODEL CARDS · TECHNICAL PAPERS

본 보고서는 Z.ai Research, GitHub, Z.ai Hugging Face Model Card, 제조사 기술 자료 및 CAISI/NIST 독립 평가를 사용했다. 제조사 벤치마크는 Z.ai 보고치로 표시하고 NIST 평가는 사이버 영역 한정으로 설명한다. Oblivion 하드웨어에서 벤치마크를 독립 재실행하지 않았다. 체크포인트, 제공자, 런타임에 따라 용량, Endpoint, 실용 컨텍스트, 라이선스가 달라질 수 있다.

주요 1차 자료

1. Z.ai Research Hub https://www.zhipuai.cn/en/research
2. Z.ai GLM-5.3 발표 https://z.ai/blog/glm-5.3
3. 공식 GLM-5 저장소 https://github.com/zai-org/GLM-5
4. Z.ai 모델 인덱스 https://huggingface.co/zai-org/models
5. NVIDIA GLM-5.3-Flash Model Card https://build.nvidia.com/z-ai/glm-5-3-flash/modelcard
6. NIST / CAISI 사이버 평가 https://www.nist.gov/news-events/news/2026/09/caisis-assessment-zais-glm-53-cyber-capabilities
7. GLM-V 저장소 https://github.com/zai-org/GLM-V
8. GLM-OCR 저장소 https://github.com/zai-org/GLM-OCR
9. GLM-ASR-Nano-2512 https://huggingface.co/zai-org/GLM-ASR-Nano-2512
10. GLM-TTS 저장소 https://github.com/zai-org/GLM-TTS
11. GLM-Image 저장소 https://github.com/zai-org/GLM-Image
12. GLM-4.5 기술 보고서 https://arxiv.org/abs/2508.06471
13. GLM-4.1V-Thinking 논문 https://arxiv.org/abs/2507.01006

> **결론의 범위**
>
> 공개 자료의 독립적 종합이지 보안 인증, 재현된 벤치마크, Z.ai의 추천 또는 Oblivion 프로덕션 시스템의 적합성 보증이 아니다.

Oblivion 엔지니어링 팀용 · Version 1.0